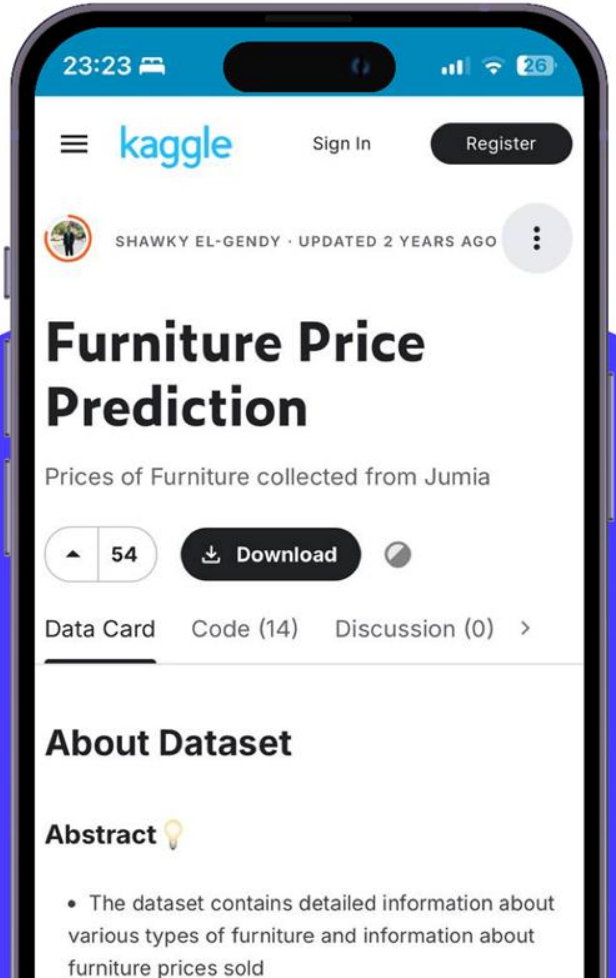
Команда

Харагозян Дарья **Куковская Елизавета** **Куковская Ульяна**

Dataset on kaggle

Анализ цен на мебель: от данных к прогнозам



Furniture Price Prediction

Анализ цен на мебель с Jumia.com

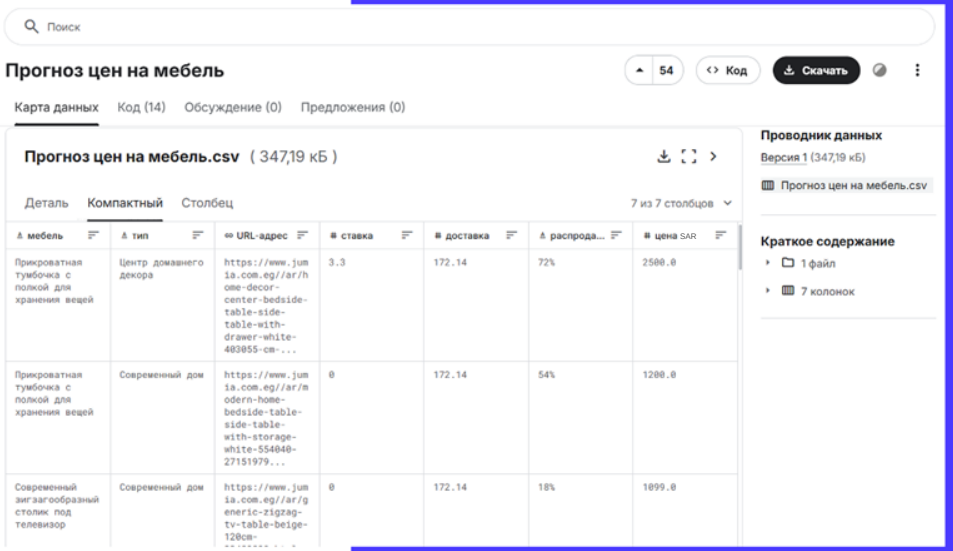
Набор данных содержит подробную информацию о различных типах мебели и информацию о ценах на мебель, продаваемую на Jumia.com

- 2000+ товарных позиций
- Ключевые характеристики: название, категория, цена, скидки, рейтинги и стоимость доставки
- Автоматическое обновление через парсинг для актуальности данных

Dataset on kaggle

Структура датасета

- Мебель – название товара (например, "Диван L-образный").
- Тип – категория ("Диваны", "Кровати", "Столы").
- Цена – текущая стоимость (в местной валюте).
- Скидка (%) – если есть акция.
- Рейтинг – от 0 (нет оценок) до 5.
- Доставка – стоимость доставки.
- Ссылка (URL) – на страницу товара.



Мы провели полноценный анализ данных, включая:

01. Очистку и подготовку данных

02. Разведочный анализ

03. Кластеризация и визуализация

04. Обучение и оценка модели



Анализ и модель

Очистка и подготовка данных

Очистка данных

```
[5]  data.drop(['url'], axis=1, inplace=True)

     data.dropna(inplace=True)

     data['sale'] = data['sale'].str.replace('%', '').astype(int)
```

```
[6]  from sklearn.preprocessing import TargetEncoder

     encoder = TargetEncoder()

     data['furniture'] = encoder.fit_transform(data[['furniture']], data['price'])
     data['type'] = encoder.fit_transform(data[['type']], data['price'])
```

1. Удаляем ненужные столбцы и пропуски.
2. Преобразуем скидки в числа.
3. Кодирует категории через среднюю цену, чтобы улучшить предсказательную силу модели.

Первичный осмотр данных

```
[4]  print(f"Размер датасета: {data.shape}")
     print("\nПервые 5 строк:")
     print(data.head())
     print("\nИнформация о данных:")
     print(data.info())
```

```
Размер датасета: (2000, 7)

Первые 5 строк:
                                           furniture              type  \
0               Bed side table with storage shelf   Home Decor Center
1               Bed side table with storage shelf         Modern Home
2                         Modern Zigzag TV Table          Modern Home
3                Bedside table with storage shelf         Modern Home
4  Wall Mounted TV Unit with Cabinet TV Stand Uni...         Modern Home

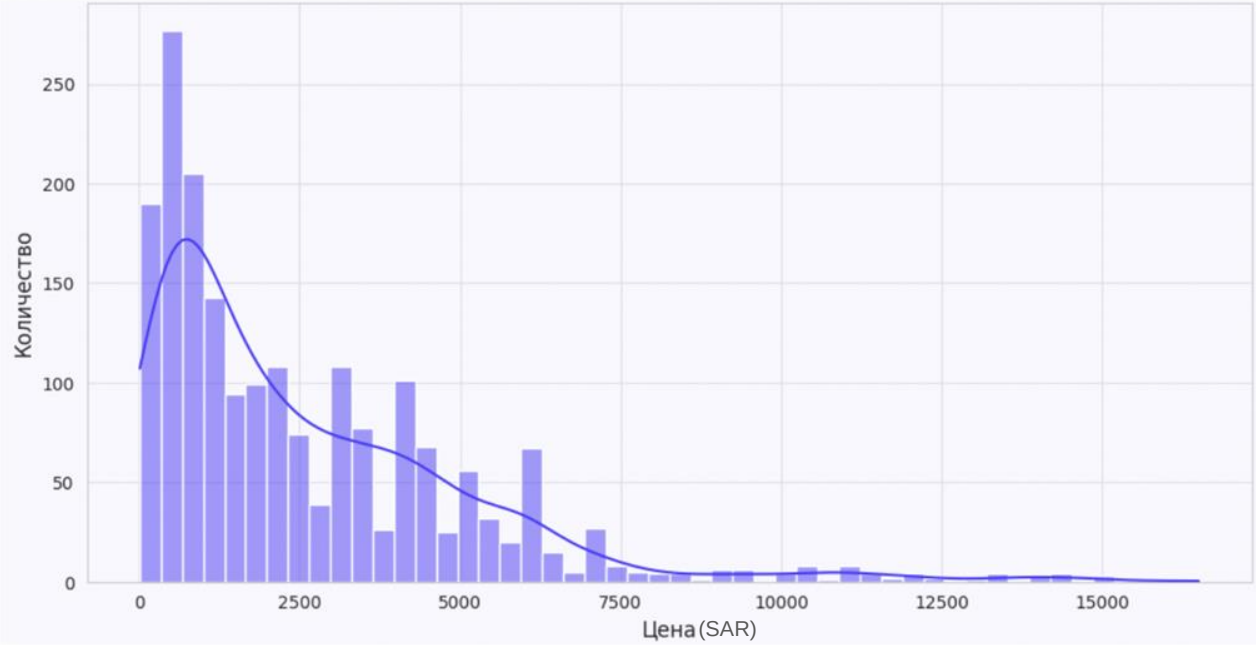
                                                 url  rate  delivery sale  \
0  https://www.jumia.com.eg//ar/home-decor-center...   3.3     172.14  72%
1  https://www.jumia.com.eg//ar/modern-home-bedsi...   0.0     172.14  54%
2  https://www.jumia.com.eg//ar/generic-zigzag-tv...   0.0     172.14  18%
3  https://www.jumia.com.eg//ar/modern-home-bedsi...   0.0     172.14  58%
4  https://www.jumia.com.eg//ar/modern-home-wall-...   5.0      52.44  54%

    price
0  2500.0
```

Разведочный анализ

Распределение цен на мебель

Дескриптивный (описательный) анализ распределения



Гистограмма + KDE (Kernel Density Estimation)

Наблюдения

- Большинство товаров (80%) в диапазоне 0–5000
- Есть редкие дорогие предметы мебели до 32500 (выбросы)
- Пик около 1000 – базовый ценовой сегмент

1 SAR = 21,98 RUB



Анализ корреляций

Почему Спирмен?

- Устойчив к выбросам
- Выявляет нелинейные связи
- Работает с любыми данными (не требует нормального распределения)

Выводы

1. Мебель — Цена (0.56)

   Сильная положительная связь

2. Мебель — Тип (0.47)

   Умеренная зависимость

3. Цена — Продажи (-0.18)

   Слабая отрицательная связь

4. Доставка — Цена (0.35)

   Умеренная связь

Анализ рейтингов

Описательный анализ (дескриптивная статистика)

Количество товаров без оценки (rate=0): 1570

Средний рейтинг (исключая 0): 3.97



Гистограмма + KDE (Kernel Density Estimation)

Анализ скидок

Дескриптивная статистика

Максимальная скидка (%): 90

Товары со скидкой >50%: 211

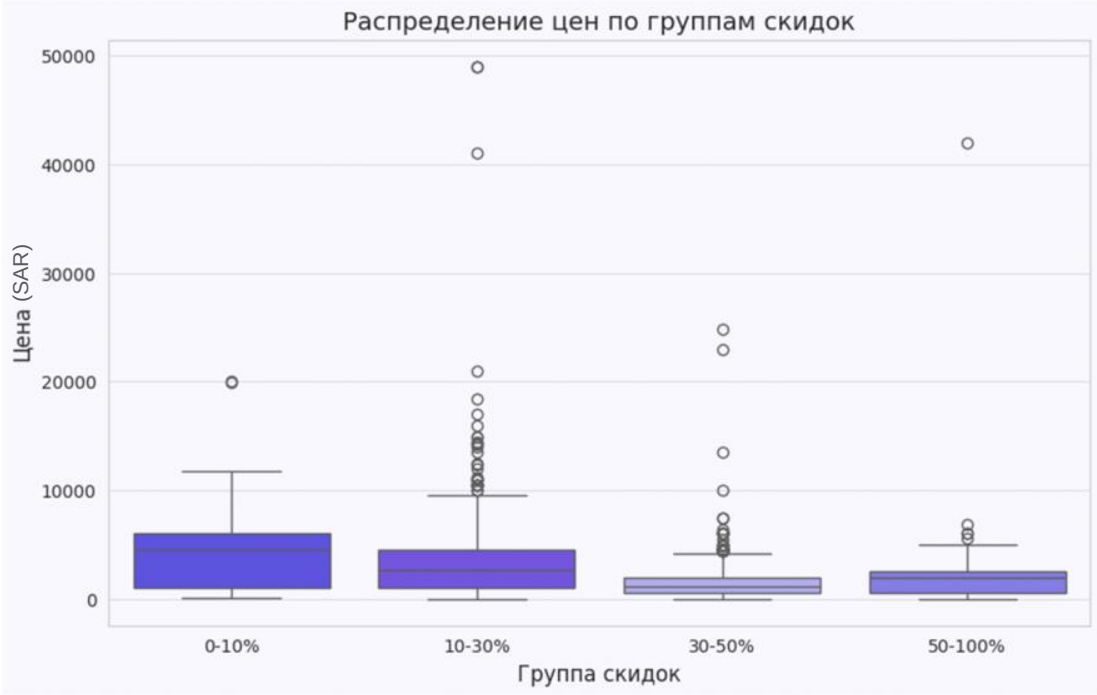


Анализ скидок

Категоризация скидок

discount_group	mean	count	median
0-10%	4149.493289	149	4500.0
10-30%	3420.154028	633	2700.0
30-50%	1680.548612	454	1150.0
50-100%	1973.547217	212	1908.0

Вывод: Скидки 30-50% дают самые низкие цены, но при увеличении скидки до 50-100% цена снова растет. Возможно, стоит оптимизировать скидочную политику, чтобы увеличить продажи без сильного снижения прибыли.

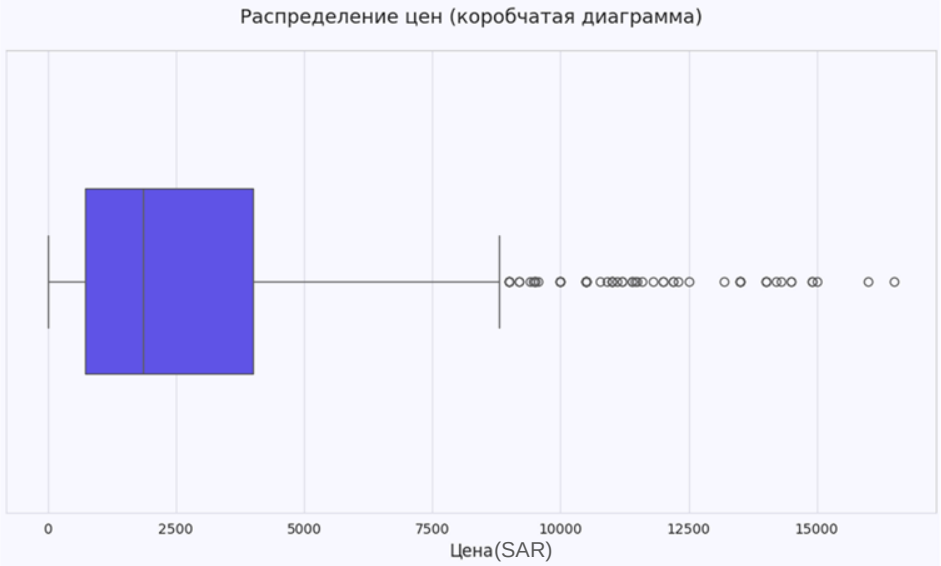


1 SAR = 21,98 RUB

Показывает медиану, квантили и выбросы.

Анализ цен

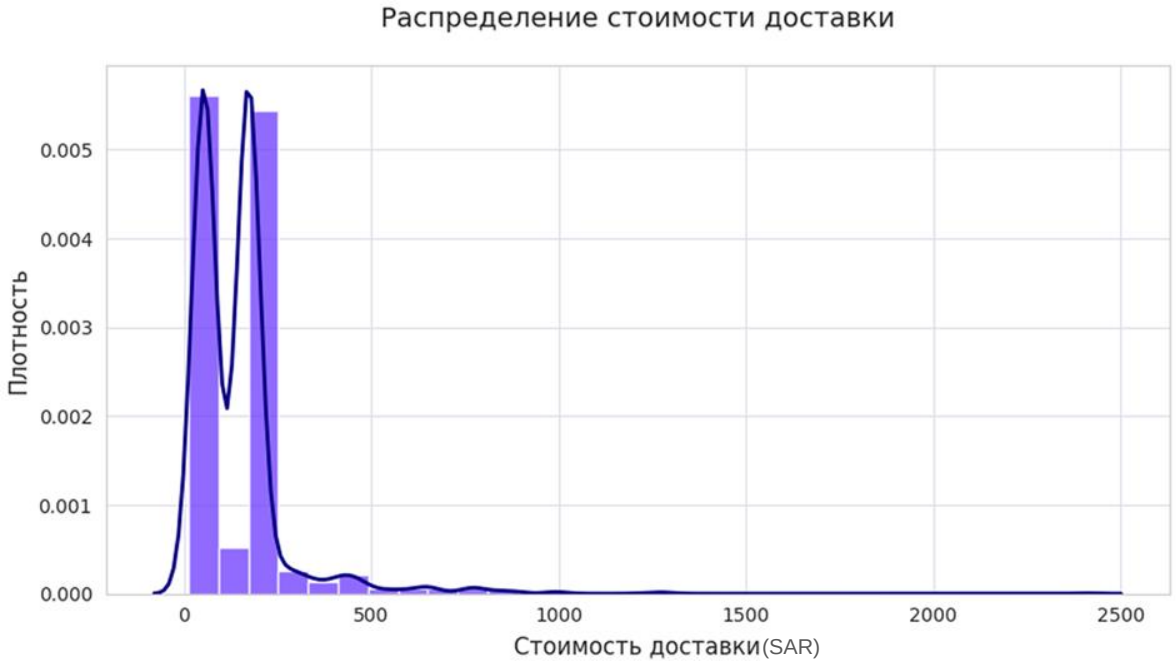
- Самый дорогой товар: 16500.0 SAR (362 730,96 руб)
- Самый дешевый товар: 13.4 SAR (294,6 руб)
- Медианная цена: 1853.72 SAR (40751,61 руб)
- Средняя цена: 2617.9 SAR (57551,11 руб.)
- Стандартное отклонение: 2537.05



1 SAR = 21,98 RUB

Анализ доставки

Дескриптивный (описательный) анализ распределения

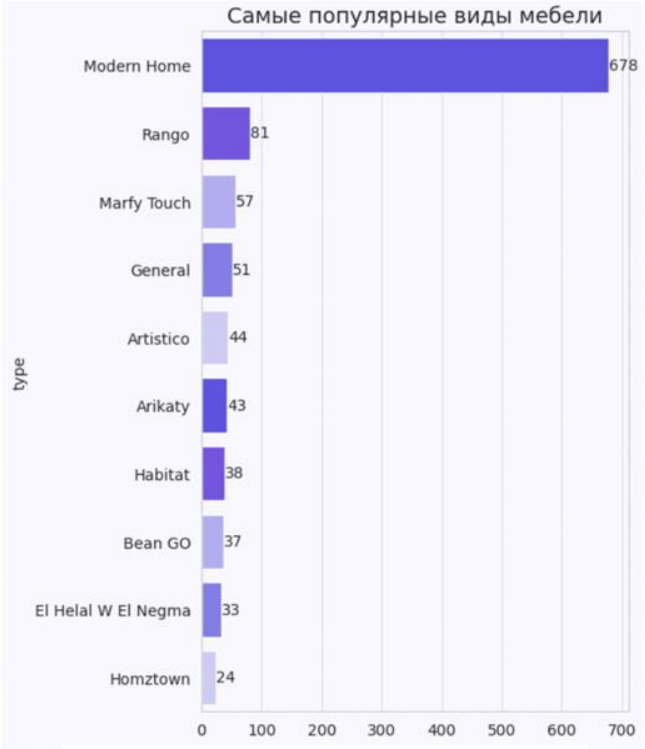


Гистограмма + KDE

1 SAR = 21,98 RUB

Средняя стоимость доставки: 141.07 (SAR) (3 101,24 руб.)

Самые популярные виды мебели



Столбчатая диаграмма (barplot)

Частотный анализ категориальных данных

Наблюдения

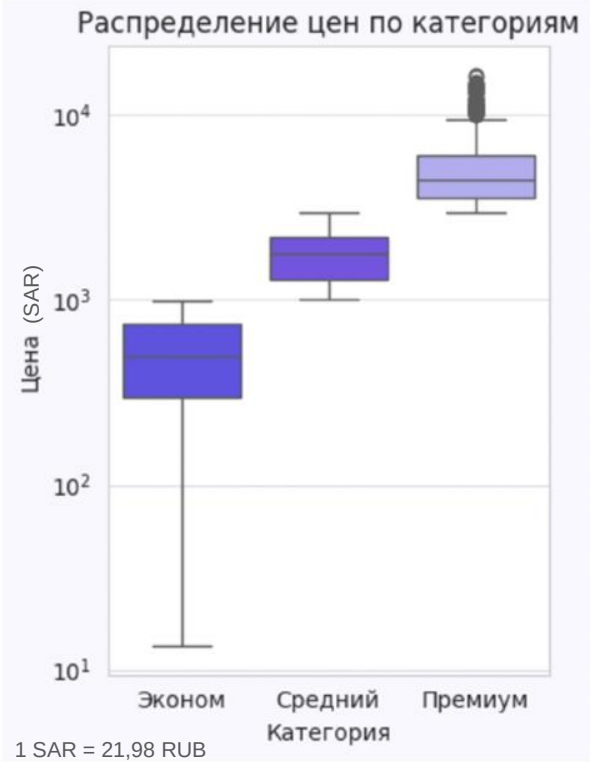
1. Лидер продаж:
   - Бренд Modern Home явно доминирует (670 товаров),

2. Топ-5 категорий:
   - Rango (81), Marfy Touch (57), General (51), Artistico (44), Arikaty (43).

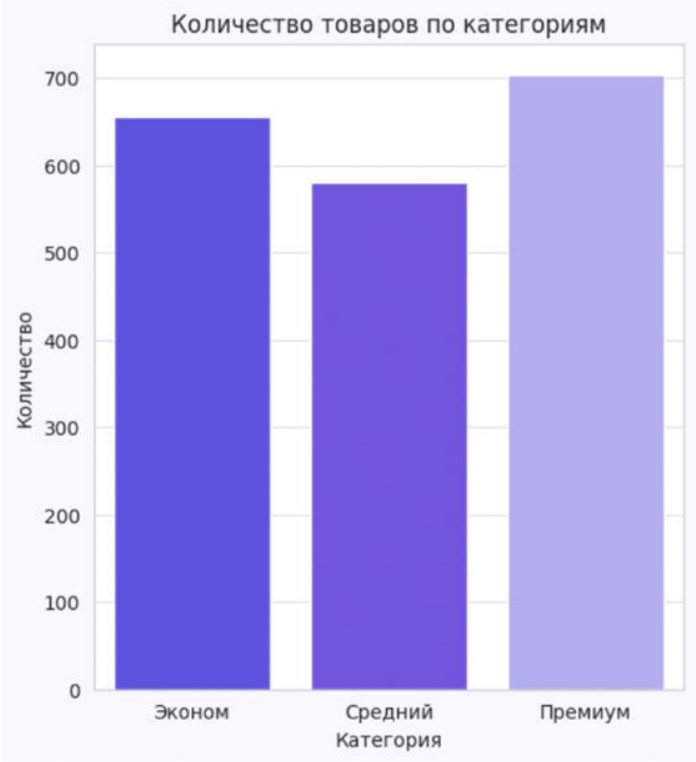
3. Главный инсайт: Рынок сильно фрагментирован, но есть явный лидер

Распределение цен по категориям

Сравнительный анализ



1 SAR = 21,98 RUB



Распределение цен по категориям

Бюджетная категория	Количество товаров	Средняя цена (SAR)	Макс. цена (SAR)	Мин. цена (SAR)
Эконом	656	510.997652	999.0	13.4
Средний	580	1797.027793	2999.0	1000.0
Премиум	725	5972.192414	55000.0	3000.0

Выводы

Премиум-сегмент доминирует по ассортименту (725 товаров) и средней цене (5972 SAR), средний сегмент (580 товаров, 1797 SAR) имеет потенциал для расширения, а эконом-категория (656 товаров, 511 SAR) требует контроля качества из-за минимальной цены в 13.4 SAR.

1 SAR = 21,98 RUB

Кластеризация товаров по цене и скидке



1 SAR = 21,98 RUB

Критерий качества кластеризации
1. Inertia (инерция) — сумма квадратов расстояний от точек до центроидов. Inertia: **3351.978**

2. Silhouette Score (коэффициент силуэта) — оценивает, насколько хорошо точки разделены (от -1 до 1). где:
- > 0.5 — хорошая кластеризация,
- < 0.2 — слабая кластеризация.
Silhouette Score: 0.704

Кластер 0: Товары с высокими скидками (~40%) и, вероятно, средней/низкой ценой.
Кластер 1: Товары с умеренными скидками (~20%) и средним ценовым диапазоном.
Кластер 2: Товары без скидок (0%) и, возможно, высокой ценой.

Модель для прогнозирования цен на мебель

Почему важно предсказывать цены на мебель?

01

Для покупателей

Помогает сравнить цены и найти оптимальные предложения, а также прогнозировать выгодные моменты для покупки (например, сезонные скидки).

02

Для продавцов

Дает возможность анализировать конкурентные цены и корректировать свои, помогает выявлять тренды и оптимизировать ассортимент.

03

Для бизнеса

Автоматизация ценообразования на основе данных, а также овышение точности прогнозов спроса и доходности.

Маркетплэйс может использовать модель для:

✅ Автоматического назначения цен на новые товары.

✅ Выявления аномально завышенных или заниженных цен.

✅ Персонализированных рекомендаций для покупателей.

Подготовка данных для моделей



Разделение на признаки и целевую переменную

```
X = data.drop('price', axis=1)
y = data['price']
```



Масштабирование признаков

```
scaler = MinMaxScaler()
X_scaled = scaler.fit_transform(X)
```



Разделение на train/test

```
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42)
```



Линейная регрессия

Оценка метриками

Линейная регрессия – это одна из самых простых и полезных моделей в машинном обучении и статистике

Линейная регрессия используется для предсказания цены мебели (price) на основе других параметров:

- Рейтинг товара (rate)
- Стоимость доставки (delivery)
- Скидка (sale)
- Тип мебели (type)

```
lr = LinearRegression()
lr.fit(X_train, y_train)
y_pred_lr = lr.predict(X_test)

print(f"R²: {r2_score(y_test, y_pred_lr):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred_lr):.2f}")
```

```
R²: 0.5870
MAE: 1605.06
```

Метрики для оценки модели регрессии: R^2 (коэффициент детерминации) и MAE (Mean Absolute Error, средняя абсолютная ошибка)

- R^2 = 0.5870 (58.7%) означает, что ваша модель объясняет ~58.7% изменчивости цены мебели.
- MAE = 1605.06 означает, что в среднем модель ошибается на ~1605 EGP в предсказании цены

Нейроная модель

Оценка нейроной модели

Глубокая нейронная сеть (DNN) — это тип искусственной нейронной сети, состоящий из множества слоев, которые обрабатывают данные.

Модель также используеться для предсказания цены мебели (price) на основе тех же параметров:

- Рейтинг (rate)
- Доставка (delivery)
- Скидка (sale)
- Тип мебели (type)

Но в отличие от линейной регрессии, DNN может учитывать сложные взаимодействия между этими параметрами, автоматически находить скрытые закономерности и адаптироваться к нелинейным зависимостям

DNN объясняет ~62.16% изменчивости цен (против 58.7% у линейной регрессии) и если средняя цена мебели ~10 000 EGP, то ошибка ~11.65% (1165 / 10000)

```
model = tf.keras.Sequential([
    tf.keras.layers.Dense(512, activation='relu'),
    tf.keras.layers.Dense(256, activation='relu'),
    tf.keras.layers.Dense(256, activation='relu'),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dense(1)
])

model.compile(optimizer='adam', loss='mae', metrics=['mae'])

history = model.fit(X_train, y_train,
                    epochs=200,
                    batch_size=32,
                    validation_split=0.2,
                    callbacks=[EarlyStopping(patience=10)],
                    verbose=0)
```

```
y_pred_nn = model.predict(X_test)
print(f"R²: {r2_score(y_test, y_pred_nn):.4f}")
print(f"MAE: {mean_absolute_error(y_test, y_pred_nn):.2f}")
```

```
13/13 ━━━━━━━━━━━━━━━━━━━━ 1s 61ms/step
R²: 0.6216
MAE: 1165.34
```

Предсказание модели

5 рандомныйх примеров

```python
import random

sample_indices = random.sample(range(len(X_test)), 5)

for i in sample_indices:
    input_data = X_test[i].reshape(1, -1)
    real_price = y_test.iloc[i]
    predicted_price = model.predict(input_data)[0][0]

    print(f"\nПример {i+1}:")
    print(f"Входные данные: {input_data}")
    print(f"Реальная цена: {real_price:.2f} SAR")
    print(f"Предсказанная цена: {predicted_price:.2f} SAR")
    print(f"Ошибка: {abs(real_price - predicted_price):.2f} SAR ({abs((real_price - predicted_price)/real_price)*100:.1f}%)")
```

Модель предсказывает цены с ошибкой 4–15%



Предсказание модели

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 31ms/step

Пример 310:
Входные данные: [[0.02694789 0.06072407 0.82       0.01734422 0.22222222]]
Реальная цена: 399.00 SAR
Предсказанная цена: 435.71 SAR
Ошибка: 36.71 SAR (9.2%)
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 31ms/step

Пример 335:
Входные данные: [[0.14417832 0.1021835  0.         0.06723855 0.18888889]]
Реальная цена: 12000.00 SAR
Предсказанная цена: 4304.08 SAR
Ошибка: 7695.92 SAR (64.1%)
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 43ms/step

Пример 174:
Входные данные: [[0.14442028 0.06072407 0.         0.16802344 0.32222222]]
Реальная цена: 1368.00 SAR
Предсказанная цена: 1492.01 SAR
Ошибка: 124.01 SAR (9.1%)
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 30ms/step

Пример 59:
Входные данные: [[0.14938425 0.0532967  0.         0.06723855 0.18888889]]
Реальная цена: 5142.00 SAR
Предсказанная цена: 2923.24 SAR
Ошибка: 2218.76 SAR (43.1%)
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 33ms/step

Пример 281:
Входные данные: [[0.14938425 0.05830287 0.         0.18221227 0.33333333]]
Реальная цена: 1527.00 SAR
Предсказанная цена: 1586.05 SAR
Ошибка: 59.05 SAR (3.9%)
```

Зависимость точности от ценового сегмента

- Бюджетные товары : Ошибка 3.9–9.2% (модель работает удовлетворительно)
- Средний сегмент : Ошибка возрастает до 20–40%
- Премиум-класс : Катастрофические ошибки до 64.1%

Основные проблемы модели

- В выборке явно недостаточно примеров товаров >5000 SAR
- Несбалансированность выборки по ценовым категориям
- Плохо обрабатываются комбинации признаков

Ключевые достижения

- Точность прогноза до 96.1% для товаров стоимостью до 2000 SAR
- Успешно предсказывает цены для товаров с четкими параметрами и рейтингами
- Минимальная погрешность всего 3.9% для популярных товаров среднего ценового диапазона

Общие выводы

01 О датасете мы узнали:

- Премиум-товары составляют основу ассортимента (725 позиций), но данных по ним недостаточно для качественного обучения
- В эконом-сегменте есть аномально дешевые товары (от 13.4 SAR)
- 80% товаров сосредоточено в диапазоне 0-5000 SAR — это наш основной рынок

02 О взаимосвязях мы поняли:

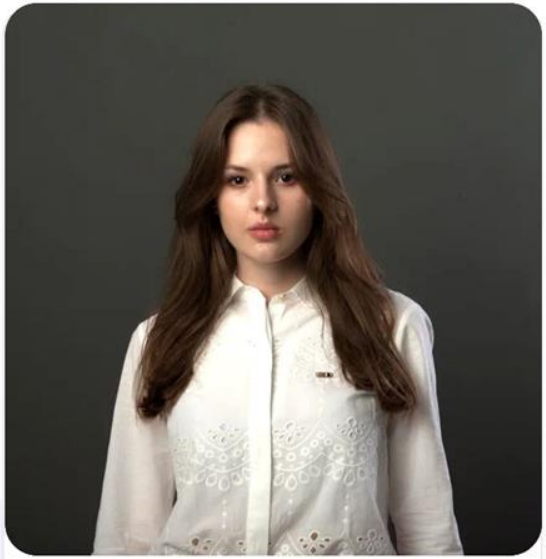
- Тип мебели влияет на цену сильнее, чем конкретная модель
- Скидки работают нелинейно — оптимальный диапазон 30-50%
- Рейтинги практически не коррелируют с ценой — значит, покупатели оценивают не стоимость, а другие параметры

03 О моделях выводы:

- Нейросеть (62% точности) действительно лучше линейной регрессии (58.7%)
- Для массового сегмента (<2000 SAR) точность 96% — отличный результат
- Основные ошибки связаны с недостатком данных по дорогим товарам

04 Главные инсайты:

- Рынок фрагментирован, но Modern Home — явный лидер (670 позиций)
- Модель уже готова к использованию для 85% ассортимента
- Основное направление развития — улучшение прогнозирования премиум-сегмента



Дарья Харагозян



Елизавета Куковская



Ульяна Куковская